## Universität Hamburg Zentrum für Bioinformatik

# Programmierung für Naturwissenschaften Sommersemester 2015 Übungen zur Vorlesung: Ausgabe am 02.07.2015

Punkteverteilung: Aufgabe 10.1: 4 Punkte, Aufgabe 10.2: 6 Punkte Abgabe bis zum 08.07.2015, 10:00 Uhr.

## Aufgabe 11.1 Geometriekonverter

Ein häufige Aufgabe für Skript-Sprachen ist die Konvertierung verschiedener Input-Formate für unterschiedliche Programme. Als Beispiel soll ein Python-Skript geokonverter.py erstellt werden, welches die Molekülgeometriedateien der Programme DALTON und TURBOMOLE sowie das allgemeine xyz-Format einlesen und in eines der anderen Formate umwandeln kann. Der Aufruf soll folgendermaßen erfolgen:

```
python3 geokonverter.py -o <Ausgabeformat> [Optionen] <Input-Datei(en)>
```

Die Angabe des Ausgabeformats (o = ORCA, t = TURBOMOLE, x = xyz-Format) ist obligatorisch, weitere Optionen sind entsprechend optional. Folgende Optionen sollen unterstüzt werden:

- -f <Datei>: Angabe einer Ausgabedatei, deren Name angegeben werden muss, andernfalls wird auf die Standardausgabe geschrieben
- -h, --help: Ausgabe eines Benutzungshinweises und eine Auflistung aller Optionen, anschließend wird das Skript beendet
- -b: Batch-Modus, es können beliebig viele Dateien angegeben werden, deren Formate alle in das Ausgabeformat konvertiert werden; Ausgaben werden durch #---# getrennt.

Machen Sie in Ihrem Skript von sinnvollen Fehlerabfragen gebrauch.

#### Hinweise:

Sie können nicht davon ausgehen, dass das Dateiformat immer über die Dateiendung zu identifizieren ist

Definition des xyz-Formats:

- ullet 1. Zeile: Anzahl der Atome im Molekül N
- 2. Zeile: Kommentarzeile, ggf. leer
- 3. bis N + 2te Zeile: Atomkoordinatenangaben Atomtyp, x, y, z

Die Atomkoordinaten werden in Ångström angegeben.

#### Definition des TURBOMOLE-Formats:

- 1. Zeile: Signalwort \$coord
- 2. bis N + 1te Zeile: Atomkoordinatenangaben x, y, z, Atomtyp
- N + 2te Zeile: beginnt mit (irgend-)einem Signalwort (eingeleitet durch \$), diese und alle weiteren Zeilen können im Input ignoriert werden, im Output soll \$end genutzt werden

Die Atomkoordinaten werden in Bohr angegeben (1 Bohr = 0,529177 Ångström).

Definition des ORCA-Formats:

- 1. Zeile: wird durch! eingeleitet und kann verschiedene Keywörter enthalten, bei der Ausgabe in ORCA-Format soll die Zeile nach! leer bleiben
- weitere Zeilen: optional können weitere Zeilen mit zusätzlichen Informationen vorhanden sein
- Geometrieblock: eingeleitet durch \*xyz <intl> <intl>, wobei <intl> die Ladung des Moleküls, <intl> die Spinmultiplizität der Wellenfunktion beschreibt; bei der Ausgabe in ORCA-Format soll von einem neutralen Molekül (Ladung = 0) ausgegangen werden, die Multiplizität soll entsprechend 1 sein, wenn die Anzahl der Elektronen gerade ist, oder 2 andernfalls.
- anschließend für jedes Atom:
  - Atomtyp, x, y, z
- abschließend \*

Die Atomkoordinaten werden in Ångström angegeben.

Zur Veranschaulichung finden Sie in STiNE die Angaben für *p*-Nitroanilin in den entsprechenden Dateien: pna.xyz (xyz-Format), pna.orc (ORCA-Format), pna.ord (TURBOMOLE-Format).

### Aufgabe 11.2 Matrixmultiplikation

Erstellen Sie ein Python-Skript, in welchem Sie drei verschiedene Möglichkeiten zur Matrixmultiplikation nutzen. Dabei soll jeweils das für eine gegebene  $N \times N$  Matrix A mit  $A_{i,j} = 1.0$  die Matrix:

$$\mathbf{B} = \mathbf{A}\mathbf{A} \tag{1}$$

berechnet werden.

Die drei zu testenden Varianten für die Matrixmultiplikation sollen auf folgenden Ansätzen beruhen:

- 1. Die Matrix wird als Liste von Listen in Python repräsentiert.
- 2. Es wird das Modul numpy verwendet.
- 3. Verwenden Sie das Modul ctypes und rufen Sie die entsprechenden Funktion aus Ihrer selbst erstellten C-Bibliothek auf. Die Matrix soll Werte vom Typ double enthalten.

Nutzen Sie außerdem das Modul time, um jeweils die Laufzeit für die drei Varianten zu bestimmen. Berechnen Sie mit allen drei oben genannten Ansätzen die Matrix B für N=25,50,100,500,1000. Berechnen Sie mit den Ansätzen zwei und drei die Matrix B auf für N=2500,5000. Geben Sie alle Laufzeiten in Sekunden in tabulierter Form aus.

Die Lösungen zu diesen Aufgaben werden am 09.07.2015 besprochen.